

Trabajo Práctico 1 (2026)

Análisis Inteligente de Datos (AID)

Tema: Exploración y limpieza (con `dirty_cafe_sales.csv`)

Vas a trabajar con una base de ventas de un café que viene *sucia* (valores faltantes y strings tipo `ERROR/UNKNOWN`). La idea es:

- explorar, describir y visualizar;
- detectar “cosas raras”;
- limpiar/completar datos con reglas claras;

Entrega

- Un **R Notebook** / **R Markdown** con tu resolución (código + breve explicación).
- Completar el **Google Form** del TP con los resultados pedidos (eso se autocorrige).

Datos

Vas a usar el archivo `dirty_cafe_sales.csv`. Tiene varias columnas, como por ejemplo:

- `Transaction ID`
- `Item`
- `Quantity`
- `Price Per Unit`
- `Payment Method`
- ...
- `Location`

Definición de “sucio” para este TP. Considerá como sucio cualquier valor:

`NA` o `ERROR` o `UNKNOWN`.

Menú (precio real por unidad)

En este TP vamos a asumir que cada `Item` tiene un precio fijo durante el año:

Item	Precio por unidad
Cookie	1.0
Tea	1.5
Coffee	2.0
Cake	3.0
Juice	3.0
Sandwich	4.0
Smoothie	4.0
Salad	5.0

Parte A – Exploración y calidad de datos

1. Lectura e inspección.

- a) Lee el CSV y reportá cuántas **filas** y **columnas** tiene.
- b) Mostrá algunas filas y comentá (muy breve) si las variables son numéricas/catógoricas/fecha.

2. Valores raros y faltantes. Para `Item`, `Quantity`, `Payment Method` y `Location`:

- a) Identificá qué valores aparecen (incluyendo `NA`/`ERROR`/`UNKNOWN`).
- b) Contá cuántos registros están “sucios” en cada columna.
- c) Hacé al menos un gráfico simple por columna (por ejemplo, barras).

3. Preguntas numéricas (van al Form).

- a) ¿Cuál es el **Item más frecuente** si ignorás `NA`/`ERROR`/`UNKNOWN`?
- b) ¿Cuál es la **Quantity menos frecuente** si ignorás `NA`/`ERROR`/`UNKNOWN`?
- c) ¿Cuántas transacciones tienen `Payment Method == Çash`?
- d) En `Location`, ¿cuántos registros están sucios y qué proporción representan del total?

4. Resumen numérico.

- a) Convertí `Price Per Unit` a numérico (y descartá lo no numérico) y calculá: media, mediana y desvío estándar.
- b) Convertí `Total Spent` a numérico (descartando lo no numérico) y sacá un resumen (mínimo, máximo, etc.).

5. Atípicos (outliers). Con `Total Spent` (numérico):

- a) Aplicá la regla del **IQR**: valores $< Q_1 - 1,5 \cdot IQR$ o $> Q_3 + 1,5 \cdot IQR$.
- b) Reportá cuántos outliers te da y cuál(es) es(son) el(los) valor(es) responsable(s).

6. Patrones temporales.

- a) Tratá `Transaction Date` como fecha. Para esta parte, usá sólo fechas válidas (descartá `NA`/`ERROR`/`UNKNOWN`).
- b) Calculá transacciones por **día de semana** y marcá el día con **máximo** y **mínimo**. ¿Cuántas transacciones hubo los viernes?
- c) Calculá transacciones por **mes** y marcá el mes con **máximo** y **mínimo**. Hacé un gráfico (barras o línea) y comentá si ves tendencia clara.

Parte B – Limpieza e imputación con reglas

A partir del dataset original, armá un **dataset de trabajo** y aplicá estos pasos **en orden** (esto te sirve para que todo el curso haga lo mismo):

1. Paso 1: completar `Price Per Unit` por menú.

En cada fila donde `Price Per Unit` esté sucio, si `Item` está limpio y es un ítem válido, reemplazá por el precio del menú. Si `Item` también está sucio, dejá `Price Per Unit` como `NA`.

2. Paso 2: completar Quantity, Price Per Unit y Total Spent cuando falte sólo una.

Interpretá ERROR/UNKNOWN como faltantes. En cada fila donde falte exactamente una de las tres variables y las otras dos estén disponibles, completá usando:

$$\text{Quantity} \times \text{Price Per Unit} = \text{Total Spent}.$$

Si para completar Quantity te da algo no entero, dejalo como NA.

3. Paso 3: completar Item usando Price Per Unit.

Si Item está sucio, completalo según el precio. Si hay más de una opción posible, usá estas reglas:

- Si Price Per Unit es 3.0, asumí Cake (y no Juice).
- Si Price Per Unit es 4.0, asumí Sandwich (y no Smoothie).

4. Checkpoint

Luego de los pasos 1–3, reportá cuántos NA quedan en Price Per Unit y en Quantity.

5. Paso 4: imputación final por moda (para dejar todo completo).

Para cada columna (Item, Quantity, Price Per Unit, Total Spent, Payment Method, Location, Transaction Date), reemplazá cualquier valor sucio por la **moda de esa columna** calculada *ignorando* valores sucios.

Si hay empate de modas, elegí el valor “más chico” según:

- numéricos: menor número;
- texto: orden alfabético;
- fechas: fecha más antigua.

6. Verificación.

Chequear que al final no queden NA/ERROR/UNKNOWN. Reportá cuántos NA quedan en todo el dataset.