

Análisis de Componentes Principales

bustoss.maxi@gmail.com [Cambiar de cuenta](#)

 Borrador guardado

El nombre, el correo y la foto asociados a tu cuenta de Google se registrarán cuando subas archivos y envíes este formulario

* Indica que la pregunta es obligatoria

Correo electrónico *

Tu respuesta

Apellido *

Tu respuesta

Nombres *

Tu respuesta

1- Aplicás PCA sin estandarizar variables y observás que una sola variable domina completamente PC1. ¿Cuál es la mejor interpretación? *

- ☐ Esa variable es la más importante del fenómeno
- ☐ PCA está identificando correctamente la estructura del dataset
- ☒ La escala de esa variable está sesgando el resultado
- ☐ El dataset no tiene correlaciones
- ☐ PCA no puede aplicarse a ese dataset

2- En un análisis, las dos primeras componentes explican solo el 40% de la varianza. ¿Qué decisión es más adecuada? *

- ☐ Usar solo esas dos componentes igualmente
- ☐ Descartar PCA automáticamente
- ☒ Evaluar si más componentes son necesarias según el objetivo
- ☐ Eliminar variables hasta aumentar la varianza explicada
- ☐ Reemplazar PCA por regresión

3- Estás usando PCA como paso previo a clustering. ¿Cuál es el principal beneficio? *

- ☐ Aumentar la cantidad de clusters detectables
- ☒ Reducir ruido y redundancia en los datos
- ☐ Garantizar clusters perfectamente separados
- ☐ Evitar la necesidad de escalar variables
- ☐ Convertir variables categóricas en numéricas

4- Observás que dos variables tienen loadings altos pero con signo opuesto en PC1. ¿Cómo lo interpretás? *

- ☐ No están relacionadas
- ☒ Tienen una relación inversa dentro de esa componente
- ☐ Deben eliminarse del análisis
- ☐ PCA está fallando
- ☐ Son outliers

5- En un biplot, un grupo de observaciones queda muy separado del resto. ¿Cuál es la mejor interpretación inicial? *

- ☐ Es un error del modelo
- ☒ Son observaciones con valores extremos o comportamiento diferente
- ☐ PCA está sobreajustando
- ☐ Deben eliminarse automáticamente
- ☐ Indican falta de escalado

6- Estás trabajando con un modelo predictivo y aplicás PCA antes de entrenarlo. *
El rendimiento baja. ¿Cuál es la explicación más probable?

- ☐ PCA siempre reduce el rendimiento
- ☐ Se perdió información relevante para la predicción
- ☐ PCA no puede usarse en machine learning
- ☐ El modelo no converge
- ☒ Las variables originales eran independientes

7- ¿Cuál es el riesgo principal de interpretar directamente las componentes principales sin analizar los loadings? *

- ☐ Perder información de varianza
- ☒ Asumir significados incorrectos de las componentes
- ☐ Reducir la dimensionalidad incorrectamente
- ☐ Aumentar el número de componentes
- ☐ Generar correlaciones artificiales

8- Tenés un dataset con muchas variables no linealmente relacionadas. ¿Qué limitación tiene PCA en este contexto? *

- ☐ No puede reducir dimensionalidad
- ☐ No puede trabajar con muchas variables
- ☒ Solo captura relaciones lineales
- ☐ No genera componentes ortogonales
- ☐ No permite visualización

9- En un análisis de clientes, PC1 se interpreta como "nivel de consumo" y PC2 como "digital vs presencial". ¿Qué valida esta interpretación? *

- ☐ El porcentaje de varianza explicada
- ☐ El algoritmo utilizado
- ☒ El análisis de los loadings de cada componente
- ☐ El número de observaciones
- ☐ La cantidad de variables originales

10- ¿Cuál de las siguientes afirmaciones refleja mejor el uso correcto de PCA en la práctica profesional? *

- ☐ Es un método para seleccionar automáticamente las mejores variables
- ☒ Es una herramienta exploratoria que requiere interpretación contextual
- ☐ Siempre mejora cualquier modelo de machine learning
- ☐ Sustituye completamente el análisis de datos
- ☐ Elimina la necesidad de entender las variables originales

11- Aplicás PCA a un dataset financiero. ¿Qué estrategia es más adecuada? *

- ☐ Usar solo PC1 para clustering
- ☒ Usar PC1 y PC2 como input para clustering
- ☐ Volver a las variables originales
- ☐ Eliminar PC2 por baja varianza
- ☐ Aplicar regresión en lugar de clustering

12- ¿Qué sucede si las variables están altamente correlacionadas? *

- ☐ PCA pierde utilidad
- ☒ PCA es especialmente útil
- ☐ PCA no puede aplicarse
- ☐ Las componentes serán iguales
- ☐ No cambia nada

13- En el contexto de PCA aplicado a detección de outliers, ¿qué indica que una componente principal tenga un eigenvalor alto? *

- ☒ Que esa dirección concentra gran parte de la variabilidad de los datos
- ☐ Que esa componente es más sensible a outliers
- ☐ Que esa componente puede descartarse sin pérdida de información
- ☐ Que las variables originales están desacopladas
- ☐ Que el modelo robusto no es necesario

14- En un análisis de PCA, se reduce un conjunto de 10 variables a 2 componentes principales que explican el 75% de la varianza total. ¿Cuál es la interpretación más adecuada? *

- ☐ No se pierde información relevante, ya que el 75% es suficiente en cualquier contexto
- ☒ Se pierde el 25% de la variabilidad, que podría contener estructura relevante o ruido
- ☐ Las variables originales dejan de estar correlacionadas completamente
- ☐ Los outliers quedan eliminados automáticamente
- ☐ El modelo resultante siempre mejora respecto al original

15- ¿En cuál de los siguientes escenarios el uso de PCA sería más apropiado en un entorno industrial? *

- ☐ Cuando se desea predecir una variable respuesta con un modelo supervisado sin pérdida de interpretabilidad
- ☒ Cuando se busca reducir dimensionalidad en datos altamente correlacionados antes de aplicar clustering
- ☐ Cuando se quiere eliminar completamente el ruido de los datos
- ☐ Cuando se requiere mantener la interpretación directa de las variables originales
- ☐ Cuando se trabaja exclusivamente con variables categóricas

16- ¿Cuál es la principal motivación para utilizar PCA robusto en lugar de PCA clásico? *

- ☐ Reducir el costo computacional
- ☐ Evitar la necesidad de estandarizar los datos
- ☒ Disminuir la influencia de outliers en la estimación de las componentes principales
- ☐ Garantizar independencia entre las variables originales
- ☐ Maximizar la varianza explicada

17- En un dataset con outliers, ¿qué efecto es esperable al aplicar PCA clásico en comparación con PCA robusto? *

- ☐ Ambos métodos identifican las mismas direcciones principales
- ☒ PCA clásico puede orientar las componentes hacia los outliers
- ☐ PCA robusto elimina completamente los outliers del dataset
- ☐ PCA robusto aumenta la varianza explicada total
- ☐ PCA clásico elimina correlaciones espurias automáticamente

18- ¿Cuál de las siguientes afirmaciones describe mejor una diferencia entre PCA clásico y PCA robusto? *

- ☐ PCA robusto utiliza la matriz de correlación en lugar de la de covarianza
- ☐ PCA clásico es inmune a valores extremos
- ☒ PCA robusto estima la estructura de los datos utilizando subconjuntos menos influenciados por outliers
- ☐ PCA robusto maximiza la varianza total sin restricciones
- ☐ PCA clásico elimina automáticamente variables redundantes

A partir de aquí vas a necesitar primero haber realizado el PCA con el dataset provisto para responder las preguntas.

19- ¿Cuál es el valor del score del individuo 20 en PC1 y en PC2? (PC1; PC2) *

- ☒ 12.204; -0.067
- ☐ -2.519; 2.898
- ☐ 3.630; 0.268
- ☐ -3.896; 1.274
- ☐ -5.567; -1.646

20- ¿Cuántas componentes son necesarias para explicar el 80% de la varianza? *

- ☐ 1
- ☐ 2
- ☐ 3
- ☒ 4
- ☐ Todas

21- ¿Cuál de las siguientes variables tiene mayor contribución (en valor absoluto) * en PC1?

- ☐ gk_reflexes
- ☐ stamina
- ☐ heading
- ☒ ball_control
- ☐ acceleration

22- ¿Qué par de variables presenta asociación negativa en el biplot? *

- ☐ Ningún par de variables
- ☐ weight y height
- ☐ age y strength
- ☒ reactions y gk_reflexes
- ☐ ball_control y crossing

23- Si el individuo 20 tiene score alto en PC1, esto indica que: *

- ☐ Tiene valores bajos en variables con loading positivo
- ☒ Tiene valores altos en variables con loading positivo
- ☐ Es un outlier
- ☐ Tiene varianza baja
- ☐ No influye en el modelo

24- En el biplot, un jugador ubicado en la dirección de "gk_reflexes" probablemente:

*

- ☐ Es jugador de campo
- ☐ Tiene bajo rendimiento
- ☒ Tiene alto valor en reflejos
- ☐ Tiene bajo score
- ☐ Es un outlier

25- Si dos jugadores están cercanos en el plano PC1–PC2, esto implica que: *

- ☐ Tienen igual posición
- ☒ Tienen perfiles similares
- ☐ Tienen misma varianza
- ☐ Tienen misma media
- ☐ Son independientes

26- La presencia de dos grupos diferenciados a lo largo de PC1 sugiere la existencia de subpoblaciones con perfiles distintos en las variables originales.

- ☒ Verdadero
- ☐ Falso

Borrar selección

27- La separación observada de dos grupos de jugadores en el biplot se explica principalmente por diferencias en PC2.

- ☐ Verdadero
- ☒ Falso

Borrar selección

28- ¿Cuál de las siguientes observaciones sería más probable que sea un outlier *
en el espacio PCA?

- ☐ Score cercano a 0 en PC1 y PC2
- ☒ Score alto en ambas componentes
- ☐ Score negativo
- ☐ Score positivo
- ☐ Score promedio

29- Según el criterio de kaiser, ¿cuántas componentes principales debería retener? *

- ☐ 1
- ☐ 2
- ☐ 3
- ☐ 4
- ☒ 5

30- Aplique la técnica robusta del Mínimo Determinante de la Covarianza (MCD) a los datos para realizar el PCA. ¿Qué porcentaje de la varianza es explicado por la primer componente? *

- ☐ 3.5%
- ☐ 50.5%
- ☒ 34.14%
- ☐ 15.86%
- ☐ 24.24%

31- ¿Cuántas componentes necesitas retener para explicar el 80% de la varianza luego de aplicar la técnica robusta? *

- ☐ 1
- ☐ 3
- ☐ 5
- ☐ 6
- ☒ 8

Adjunte el archivo .html *

Sube 1 archivo compatible. Tamaño máximo: 10 MB.

 [Añadir archivo](#)

Adjunte el archivo .Rmd

Sube 1 archivo compatible. Tamaño máximo: 10 MB.

 [Añadir archivo](#)

Enviar

Página 1 de 1

[Borrar formulario](#)

Nunca envíes contraseñas a través de Formularios de Google.

Este contenido no ha sido creado ni aprobado por Google. - [Contactar con el propietario del formulario](#) - [Términos del Servicio](#) - [Política de Privacidad](#)

¿Parece sospechoso este formulario? [Informe](#)

Google Formularios

